TRABALHO DE CONCLUSÃO DE CURSO — RELATÓRIO TÉCNICO DE EVOLUÇÃO

Relatório de Atualização de Arquitetura e Status

PROJETO
Vila Cachos AI — Sistema Especialista B2B para Recomendação Híbrida

DATA
05 de Outubro de 2026

ALUNO
Marcos Vinícius

DESTINATÁRIO
Prof.(a) Orientador(a)

1. Resumo Executivo do Status Atual

O **Vila Cachos AI** encontra-se com seu **núcleo de inteligência validado**: o pipeline composto por anamnese estruturada, clusterização não supervisionada (K-Means) e ranqueamento de produtos com suavização bayesiana está plenamente funcional e integrado em uma arquitetura cliente-servidor desacoplada (React/Vite no front-end e FastAPI no back-end).

Durante a validação prática, identificou-se que a principal fonte de incerteza do sistema **não reside no motor de recomendação, mas na entrada de dados**: a classificação manual de variáveis morfológicas (curvatura e nível de frizz) é intrinsecamente subjetiva e sujeita à variabilidade perceptual entre diferentes profissionais. Para mitigar esse viés sistemático, propõe-se a **incorporação de um módulo de Visão Computacional baseado em YOLO**, capaz de automatizar a extração dessas variáveis morfológicas diretamente a partir de fotografias capturadas em ambiente de salão.

Com essa evolução, o projeto migra de um sistema especialista fundamentado puramente em entrada declarativa para um **sistema híbrido multimodal** (dados tabulares + visão computacional), elevando significativamente sua robustez metodológica, reprodutibilidade e relevância científica.

Componente do Sistema	Status de Desenvolvimento
Anamnese guiada (8 variáveis tabulares)	✓ Validado
Clusterização K-Means (4 personas capilares)	✓ Validado
Score ponderado de produto + Média Bayesiana	✓ Validado
Arquitetura Front-end (React/Vite) & Back-end (FastAPI)	✓ Validado
Módulo de Visão Computacional (YOLO para detecção e segmentação)	⚙ Em Especificação / Treinamento

2. Arquitetura Base Validada

2.1 Coleta e Estruturação de Dados

A anamnese digital captura **8 variáveis essenciais**: curvatura da fibra capilar (tipos 2A a 4C), porosidade, histórico de danos químicos e 5 queixas capilares frequentes (frizz, ressecamento, quebra, oleosidade na raiz e perda de definição). Esses atributos são codificados e normalizados, compondo o vetor de características da cliente.

2.2 Segmentação via K-Means (Scikit-Learn)

O vetor de características é submetido a um modelo não supervisionado **K-Means com $k = 4$**, associando a cliente a uma de quatro **personas capilares**. A determinação do hiperparâmetro k fundamentou-se em análises de agrupamento (método do cotovelo e coeficiente de silhueta), assegurando separabilidade estatística e interpretabilidade sob a ótica da tricologia aplicada.

2.3 Ranqueamento e Suavização Bayesiana de Feedback

O score final de cada produto conjuga a compatibilidade com a persona e as avaliações empíricas dos profissionais (notas de 1 a 5). Para neutralizar distorções estatísticas decorrentes de *cold start* (poucos feedbacks), aplica-se a **Média Bayesiana ponderada**:

$$S_{bayes} = \frac{C \cdot m + \sum_{i=1}^{n} r_i}{C + n}$$

Onde m representa a média global do catálogo, C é o peso de confiança mínima e n é a quantidade de avaliações do produto com notas r. Dessa forma, produtos novos com poucas notas máximas não superam produtos consolidados no catálogo.

3. Integração com YOLO (Visão Computacional)

3.1 Motivação e Justificativa Tecnológica

O objetivo do módulo de visão é **automatizar a detecção da curvatura e a quantificação do nível de frizz capilar a partir de imagens reais capturadas no salão**, minimizando a margem de erro humano e o tempo de preenchimento da anamnese manual.

A opção pela arquitetura **YOLO** (*You Only Look Once*) — especificamente implementações da família Ultralytics (YOLOv8/YOLO11) — fundamenta-se nas seguintes premissas técnicas:

- **Inferência em tempo real:** Topologia *single-stage* otimizada para execução em dispositivos de balcão e servidores de aplicação de custo acessível, viabilizando resposta instantânea.
- **Suporte a tarefas híbridas:** Capacidade nativa de combinar segmentação de instâncias (delimitando a mecha capilar e isolando o fundo) com classificação hierárquica das curvaturas.
- **Eficiência em Transfer Learning:** Pesos pré-treinados que permitem convergência acurada mesmo com datasets específicos e controlados de salão.
- **Homogeneidade de ecossistema:** Integração nativa em Python, viabilizando execução direta no mesmo pipeline assíncrono do FastAPI existente.

3.2 Encaixe no Fluxo de Diagnóstico (Casos de Uso)

- **UC-01 — Realizar Anamnese Capilar:** A profissional fotografa a fibra capilar; o modelo YOLO isola a região do cabelo, prevê a classe da curvatura (2A a 4C) e infere o nível de frizz juntamente com a métrica de confiança. Os dados preenchem automaticamente a ficha clínica. Caso a confiança fique abaixo de um limiar estipulado (τ), ativa-se o protocolo *human-in-the-loop* para validação da profissional.
- **UC-02 — Gerar Diagnóstico e Recomendação:** Os atributos validados alimentam o vetor de entrada do modelo K-Means, mantendo a compatibilidade estrita com a lógica de personas e com a Média Bayesiana já consolidadas.

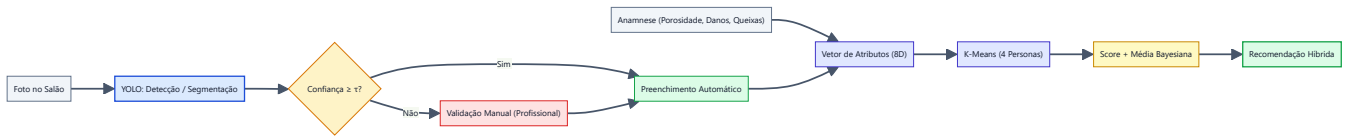


Figura 1: Arquitetura integrada do fluxo de diagnóstico multimodal (YOLO → K-Means → Média Bayesiana).

3.3 Valor Tecnológico e Rigor Científico

1. **Objetividade e Reprodutibilidade:** Substitui a avaliação exclusivamente perceptual por uma métrica determinística, possibilitando a mensuração formal da concordância diagnóstica (ex.: coeficiente Kappa de Cohen).
2. **Arquitetura Multimodal Completa:** Estabelece uma ponte metodológica entre aprendizado supervisionado (visão computacional), não supervisionado (K-Means) e inferência estatística (Média Bayesiana).
3. **Hipótese Experimental Verificável:** Permite comprovar se o uso de visão computacional na entrada estabiliza a atribuição de personas e reduz a variância nas recomendações de produtos.
4. **Contribuição para a Comunidade:** Formação e curadoria de uma base rotulada de curvaturas capilares brasileiras — segmento notadamente sub-representado em datasets públicos de visão.

4. Próximos Passos e Cronograma Técnico (Roadmap)

#	Etapa Metodológica	Entregável Técnico
1	**Construção e Anotação do Dataset:** Coleta padronizada de imagens no salão parceiro e anotação bounding box/segmentação com balanceamento (curvaturas 2, 3 e 4).	Dataset versionado + Protocolo de anotação e consentimento LGPD
2	**Treinamento e Fine-Tuning do YOLO:** Transfer learning com aumentação de dados (variação de iluminação, ruído e contraste).	Pesos treinados e serializados (`best.pt` / formato ONNX)
3	**Avaliação e Validação Empírica:** Análise de mAP50, precisão, recall, F1-Score por curvatura e matriz de confusão.	Relatório formal de métricas e convergência
4	**Integração na API FastAPI:** Implementação do endpoint assíncrono `POST /diagnostico/imagem` para inferência em tempo real.	Documentação interativa OpenAPI/Swagger
5	**Interface de Captura no Front-end:** Componente React para upload/captura de câmera e interface de conferência *human-in-the-loop*.	Módulo de captura integrado e responsivo
6	**Estudo Comparativo e Análise Estatística:** Comparação entre preenchimento puramente manual vs. assistido por IA no salão.	Capítulo de Resultados e Discussão do TCC
7	**Consolidação da Monografia:** Atualização dos diagramas UML, casos de uso e fundamentação teórica.	Texto final da monografia revisado

⚠ Gestão de Riscos e Estratégias de Mitigação

- **Variabilidade de iluminação no salão:** Mitigada mediante protocolo físico de enquadramento e técnicas de *data augmentation* (HSV jitter, rotações e ruído gaussiano).
- **Desbalanceamento amostral:** Coleta orientada e ponderação da função de custo (*class weights*) para curvaturas com menor representatividade.
- **Incerteza na inferência:** Mecanismo de fallback *human-in-the-loop*; imagens com índice de confiança inferior ao limiar τ são obrigatoriamente submetidas à validação manual do profissional.
- **Conformidade LGPD:** Processamento estrito da fibra capilar (sem armazenamento desnecessário de traços faciais) e termo formal de esclarecimento e consentimento.

Coloco-me à inteira disposição para alinharmos o escopo de anotação do dataset e a granularidade das métricas na próxima reunião de orientação.

Respeitosamente,

Marcos Vinícius

Graduando em Ciência / Engenharia da Computação